Tres maneras de agrupar vinos: contraste entre clustering y reducción dimensional

Carlos Mario Salvatore Ocampo Aguilar

Universidad de Cundinamarca

Especialización en Inteligencia Artificial

604012 – Introducción a Machine Learning

28 de octubre de 2026

Tres maneras de agrupar vinos: contraste entre clustering y reducción dimensional

Un mismo conjunto puede formar grupos diferentes según la definición de semejanza. El informe contrasta centroides, fusiones jerárquicas y distribuciones gaussianas sobre mediciones químicas de vinos. Además pregunta cuánto del conjunto puede representarse en un plano sin confundir una figura atractiva con una descripción completa. La guía de ML no supervisado del curso propone evaluar agrupamientos mediante inercia, silueta y el índice Davies–Bouldin, además de emplear PCA para reducir dimensiones (Universidad de Cundinamarca, s. f.). El ejercicio completo, con salidas guardadas y gráficos reproducibles, se encuentra en https://github.com/Salv4tore27/carlos-ml-no-supervisado-vinos.

Qué aporta cada técnica

En un análisis no supervisado las categorías no sirven de objetivo durante el ajuste. El clustering propone una partición; PCA y SVD describen una representación de menor rango. Para control exploratorio de lotes, una partición podría ayudar a seleccionar muestras para análisis químico adicional y una proyección a revisar tendencias. Esa aplicación requeriría validación con lotes reales: las clases del conjunto Wine no son una medida de calidad ni permiten concluir que un vino sea mejor.

K-means representa cada grupo por su media y minimiza la suma de distancias cuadradas a esos centroides; es sensible a escalas y valores extremos. Ward combina grupos desde abajo según el aumento de dispersión interna y conserva una jerarquía que puede cortarse a diferentes alturas. La mezcla gaussiana modela densidades mediante medias, covarianzas y pesos; en este experimento su asignación final toma el componente más probable. Su flexibilidad requiere estimar más parámetros y no garantiza un resultado superior. Esta comparación permite distinguir particiones por centroides, jerarquías y un modelo probabilístico (Scikit-learn developers, s. f.-a).

Datos y decisiones de análisis

Se utilizaron las 178 observaciones y 13 características de `load_wine`, copia integrada del conjunto Wine en scikit-learn (Scikit-learn developers, s. f.-b). Sus tres clases conocidas se mantuvieron fuera del ajuste. Como las desviaciones originales de las variables difieren mucho, se aplicó `StandardScaler` antes de calcular distancias. Este paso altera qué se considera cercano; todos los resultados se refieren a esa escala estandarizada. No hubo datos faltantes.

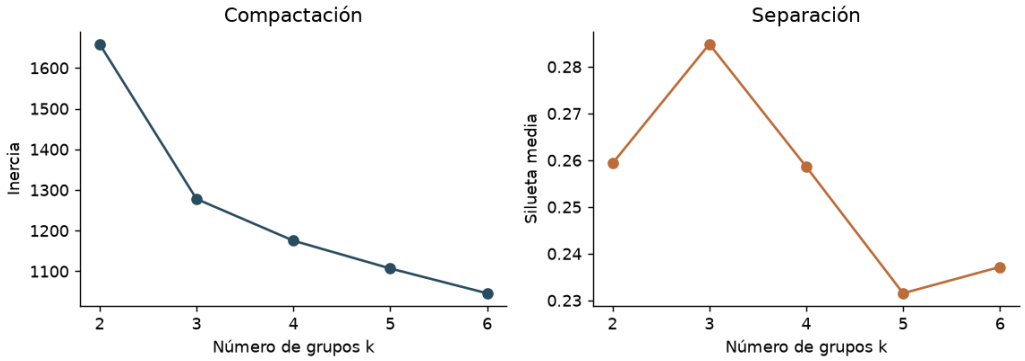
Se probaron modelos K-means con k de 2 a 6, 20 inicializaciones y semilla 42. La inercia informa compactación respecto de centroides; su descenso al aumentar k no demuestra, por sí solo, cuál es el mejor número de grupos. La silueta relaciona cohesión y separación, por lo que se leyó junto con la curva de inercia (Scikit-learn developers, s. f.-a). Después se fijaron tres grupos para comparar K-means, Ward y una mezcla gaussiana de covarianza completa con 10 inicializaciones. Ward fusiona conjuntos minimizando el aumento de varianza; la mezcla permite describir grupos mediante medias y covarianzas. Ninguna clase de procedencia ingresó como variable predictora. Para cada partición se calculó silueta, Davies–Bouldin (menor indica mejor separación según su definición) y ARI frente a las clases conocidas. El ARI es una comprobación externa, realizada después del agrupamiento, y no convierte el ejercicio en aprendizaje supervisado. La diferencia entre estas medidas importa: dos métodos pueden tener una silueta parecida y discrepancias en las asignaciones individuales.

Comparación de agrupamientos

En la Figura 1 la mayor silueta de los valores ensayados aparece con $k = 3$ (0,2849). La diferencia frente a otros valores debe interpretarse con moderación: el conjunto tiene 13 dimensiones y una silueta de 0,28 no significa separación perfecta. El codo de la inercia tampoco constituye una prueba única del número de grupos.

Figura 1

Selección de grupos K-means mediante inercia y silueta



Nota. Los cálculos se hicieron sobre 13 variables estandarizadas. Cada k se ajustó con 20 inicializaciones y semilla 42. Datos de `resultados/seleccion_k.csv`; elaboración propia.

Tabla 1

Resultados de tres modelos con tres grupos

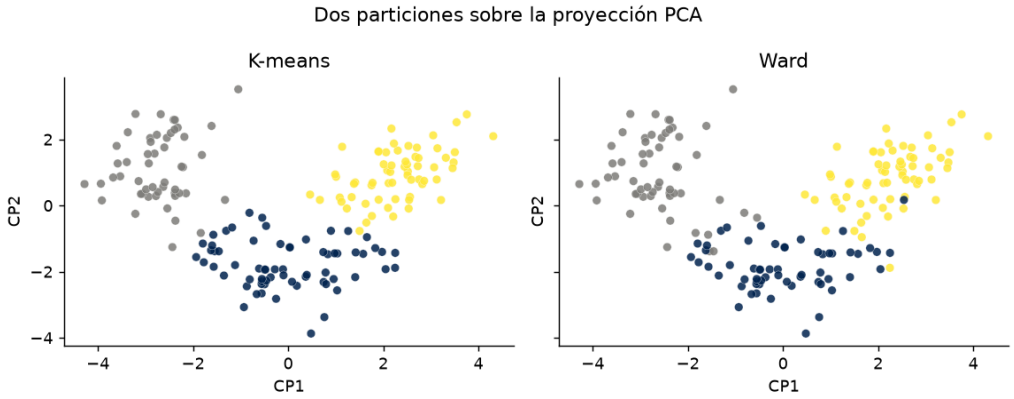
Método	Silueta	Davies–Bouldin	ARI externo
K-means	0,2849	1,3892	0,8975
Ward	0,2774	1,4186	0,7899
Mezcla gaussiana	0,2844	1,3938	0,8804

Nota. ARI compara con clases reservadas para evaluación. Los tamaños de grupo fueron 65/51/62 para K-means, 58/56/64 para Ward y 63/64/51 para la mezcla; el orden numérico de las etiquetas no tiene significado. Datos de `resultados/comparacion_metodos.csv`; elaboración propia.

Como resume la Tabla 1, K-means obtuvo el mayor ARI (0,8975), mientras Ward alcanzó 0,7899. La mezcla gaussiana quedó entre ambos (0,8804). Sus siluetas se encuentran cerca de 0,28, por lo que esa medida interna por sí sola habría ocultado parte de la diferencia respecto de la procedencia conocida. La Figura 2 dibuja dos particiones en el mismo plano PCA, pero el ajuste se hizo en las 13 dimensiones originales estandarizadas; la proyección no intervino en la asignación.

Figura 2

Particiones de K-means y Ward en el plano PCA



Nota. Los colores identifican grupos encontrados, no las clases de procedencia. Los mismos ejes permiten comparar la forma de ambas particiones. Elaboración propia.

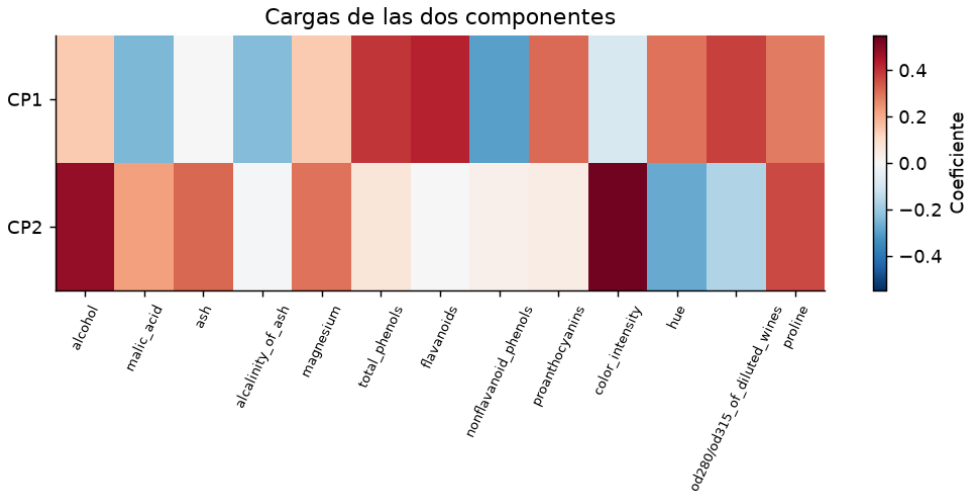
El costo de dibujar trece variables en dos ejes

PCA retuvo 55,41 % de la varianza total en dos componentes. Se calculó también la SVD de la matriz centrada y se reconstruyó con sus dos mayores valores singulares. El error relativo de reconstrucción fue 0,6678; la diferencia máxima frente a la reconstrucción PCA fue $3,33 \times 10^{-15}$. La coincidencia numérica es la esperada porque PCA puede expresarse mediante SVD sobre datos centrados (Scikit-learn developers, s. f.-c). Lo que no coincide es el plano con el espacio completo: cerca del 44,59 % de la varianza queda fuera de esa vista.

La Figura 3 ayuda a interpretar qué variables contribuyen a cada eje; coeficientes de signo opuesto indican direcciones contrarias dentro de una componente, no relaciones causales. La Figura 4 complementa esa lectura con el espectro de varianza y las últimas fusiones de Ward.

Figura 3

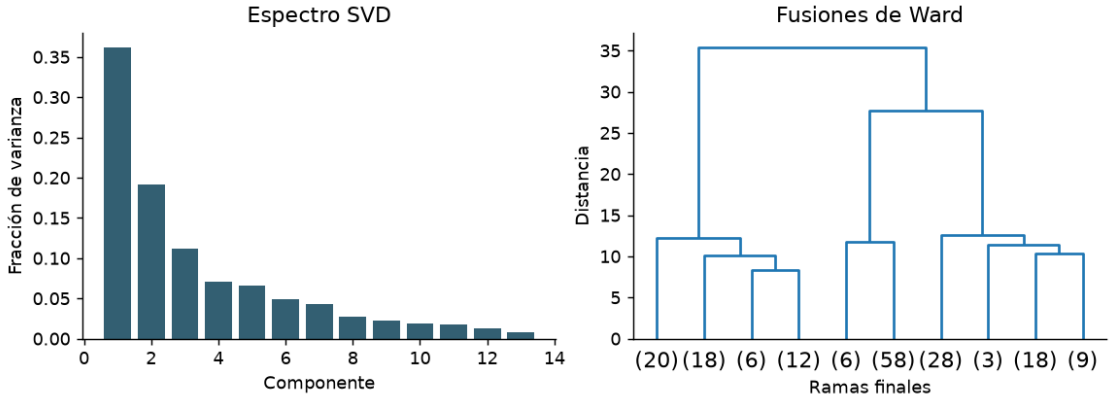
Cargas de las trece variables en las dos primeras componentes



Nota. Cargas calculadas sobre variables estandarizadas. La orientación de un eje PCA puede invertirse sin cambiar la solución. Elaboración propia.

Figura 4

Varianza por componente y jerarquía de Ward



Nota. La fracción de varianza se calcula normalizando los valores singulares al cuadrado. El dendrograma está truncado a diez hojas, que pueden representar conjuntos de observaciones. Elaboración propia.

El espectro muestra que conservar solo dos componentes elimina contribuciones de los ejes restantes. Algebraicamente, si $X_c = U\Sigma V^{\mathsf{T}}$, se usó $X_2 = U_2\Sigma_2 V_2^{\mathsf{T}}$ y el error $\|X_c - X_2\|_F / \|X_c\|_F$. Su cuadrado, $0{,}6678^2 \approx 0{,}4459$, coincide con la fracción de varianza descartada. Por tanto, observar grupos próximos o superpuestos en dos dimensiones no prueba que lo estén igualmente en las

trece mediciones.

En la comparación interna, K-means supera por apenas 0,0005 puntos de silueta a la mezcla gaussiana; esa diferencia no es evidencia de superioridad general ni una prueba estadística. Frente a Ward la diferencia de ARI externo es 0,1076. A su vez, el ARI entre las particiones de K-means y Ward es 0,8530: ambas comparten bastante estructura, pero discrepan en asignaciones. El dendrograma ayuda a examinar esa organización; su altura mide la distancia de fusión y no una confianza estadística.

Conclusiones

Los tres algoritmos encontraron grupos con alguna relación con la procedencia conocida, aunque no con la misma precisión externa. K-means presentó el mayor ARI del ejercicio, pero esa ventaja no autoriza afirmar que siempre sea superior: depende de los datos, de la escala y del criterio de comparación. Ward muestra una partición distinta construida por fusiones, y la mezcla gaussiana ofrece una alternativa probabilística con supuestos más flexibles. Las siluetas próximas entre modelos ilustran por qué el resultado debe evaluarse con más de una medida.

Reducir a dos dimensiones hizo posible comparar los grupos visualmente, pero descartó una parte considerable de la variación. SVD permitió medir esa pérdida y verificar la relación algebraica con PCA. Si el objetivo fuera segmentar vinos nuevos, harían falta un conjunto externo, análisis de estabilidad ante otras muestras y una justificación de qué variables químicas importan para la decisión. Los archivos del notebook permiten repetir los cálculos; las conclusiones se limitan al conjunto Wine y a las decisiones declaradas.

Reproducción y evidencia de ejecución

El cuaderno se ejecutó de principio a fin en Google Colab el 27 de octubre de 2026, sin errores. Puede abrirse mediante el enlace siguiente y elegir *Entorno de ejecución* >*Ejecutar todo*. Los datos están incluidos en scikit-learn: no se requiere cargar archivos, conectar Drive ni proporcionar credenciales. Las celdas siguen el orden carga, estandarización, comparación de k,

ajuste de modelos, evaluación, reducción y exportación.

Abrir el cuaderno de Carlos en Google Colab.

El repositorio enlazado en la introducción contiene el notebook con salidas visibles, instrucciones de ejecución en el README, dependencias y la carpeta `resultados/`. Allí, `seleccion_k.csv` respalda la elección de grupos, `comparacion_metodos.csv` respalda la tabla de evaluación y `resumen.json` conserva las medidas de reducción. Las figuras PNG se regeneran desde las mismas celdas. Las diferencias próximas a 10^{-15} entre ejecuciones de PCA y SVD corresponden al redondeo de punto flotante; no alteran las conclusiones ni deben interpretarse como cambios sustantivos.

Referencias

Scikit-learn developers. (s. f.-a). *Clustering*. scikit-learn. https://scikit-learn.org/stable/modules/clustering.html

Scikit-learn developers. (s. f.-b). *load_wine*. scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_wine.html

Scikit-learn developers. (s. f.-c). *PCA*. scikit-learn. https://scikit-learn.org/stable/modules/generated/sklearn.decomposition.PCA.html

Universidad de Cundinamarca. (s. f.). *Guía implementación de Machine Learning no supervisado* [Material del curso]. https://posgrado.ucundinamarca.edu.co/mod/resource/view.php?id=73633